🚀 AI & ML Deep Dive

পর্ব ০৩ - রেইনফোর্সমেন্ট লার্নিং (Reinforcement Learning)

আমাদের ১২ দিনের মেগা সিরিজের তৃতীয় পর্বে আপনাদের স্বাগতম।

গত দুই পর্বে আমরা যা শিখেছি:

✅ সুপারভাইজড লার্নিং: শিক্ষকের (Labeled Data) সাহায্যে শেখা।

✅ আনসুপারভাইজড লার্নিং: কোনো শিক্ষক ছাড়াই নিজে নিজে প্যাটার্ন খোঁজা।

আজ জানবো এআই-এর সবথেকে রোমাঞ্চকর এবং শক্তিশালী শাখা রেইনফোর্সমেন্ট লার্নিং সম্পর্কে। এটি এমন এক পদ্ধতি যেখানে মেশিন "শাস্তি এবং পুরস্কার" এর মাধ্যমে নিজের অভিজ্ঞতা থেকে শেখে। 🤖🏆

🚲 সাইকেল চালানোর সেই গল্প (Trial and Error)

মনে পড়ে প্রথমবার সাইকেল চালানোর কথা? কোনো বই পড়ে কি ব্যালেন্স করা শিখেছিলেন? মোটেও না!

১. প্রথমবার আপনি পড়ে গিয়েছেন। ব্যথা পেয়েছেন (শাস্তি বা Penalty)।

২. পরের বার আপনি আরেকটু সাবধানে চেষ্টা করেছেন।

৩. বারবার ভুল এবং চেষ্টার মাধ্যমে আপনি বুঝতে পেরেছেন ঠিক কতটুকু হ্যান্ডেল ঘুরালে পড়ে যাবেন না।

রেইনফোর্সমেন্ট লার্নিং ঠিক এভাবেই কাজ করে। এখানে মেশিনকে কোনো উত্তর বলে দেওয়া হয় না, সে নিজে কাজ করে এবং ফলাফলের ভিত্তিতে নিজের ভুল শুধরে নেয়।

মেশিন লার্নিংয়ের ভাষায় একেই বলে Trial and Error (ভুল ও চেষ্টার মাধ্যমে শেখা)। মেশিন এখানে কোনো ডেটা বা লেবেল থেকে শেখে না, বরং নিজের কাজের ফলাফল বা অভিজ্ঞতার ওপর ভিত্তি করে শেখে।

🔍 রেইনফোর্সমেন্ট লার্নিং আসলে কী?

রেইনফোর্সমেন্ট লার্নিং কোনো স্ট্যাটিক ডেটাসেট নিয়ে কাজ করে না বরং এটি একটি Continuous Loop বা চক্রের মতো কাজ করে। এই চক্রটি মূলত ৫টি প্রধান স্তম্ভের ওপর দাঁড়িয়ে:

১. Agent (এজেন্ট) — "মূল শিক্ষার্থী"

এজেন্ট হলো সেই সত্তা বা এআই মডেল যা শিখছে এবং সিদ্ধান্ত নিচ্ছে। সে শুরুতে পরিবেশ সম্পর্কে কিছুই জানে না। সে কেবল পর্যবেক্ষণ করে এবং বিভিন্ন পদক্ষেপ নেওয়ার চেষ্টা করে।

২. Environment (পরিবেশ) — "কাজের জগত"

এজেন্ট যে জগতের ভেতরে অবস্থান করছে এবং কাজ করছে, তাকেই এনভায়রনমেন্ট বলে। এটি বাস্তব পৃথিবী হতে পারে (যেমন: একটি ড্রোন যখন আকাশে ওড়ে) অথবা ভার্চুয়াল হতে পারে (যেমন: একটি ভিডিও গেম বা সিমুলেটর)।

৩. State (অবস্থা) — "বর্তমান মুহূর্তের ছবি"

একটি নির্দিষ্ট সময়ে পরিবেশের পরিস্থিতি কেমন, তাকেই বলা হয় স্টেট (State)। এটি অনেকটা বর্তমান মুহূর্তের একটি স্ন্যাপশট।

৪. Action (কাজ) — "সিদ্ধান্ত ও পদক্ষেপ"

এজেন্ট তার বর্তমান স্টেট দেখে যে কাজগুলো করার ক্ষমতা রাখে, সেগুলোই হলো অ্যাকশন।

৫. Reward (পুরস্কার ও শাস্তি) — "একমাত্র গাইড"

রেইনফোর্সমেন্ট লার্নিংয়ে কোনো শিক্ষক নেই, আছে শুধু 'রিওয়ার্ড'। এটি একটি সংখ্যাগত মান (Numerical Value) যা এজেন্টকে জানায় তার কাজটি কতটুকু ভালো বা মন্দ ছিল।

➜ পুরস্কার (+1): ড্রোনটি যদি বাধা এড়িয়ে সঠিক গন্তব্যে এগোয়।

➜ শাস্তি (-1): ড্রোনটি যদি কোনো গাছের সাথে ধাক্কা খায় বা লক্ষ্য থেকে দূরে সরে যায়।

➜ লক্ষ্য: এজেন্টের একমাত্র টার্গেট থাকে দিনশেষে Total Reward বা মোট পয়েন্ট সর্বোচ্চ করা।

🔄 এই ৫টি অংশ একসাথে একটি চক্রের মতো কাজ করে:

১. Agent বর্তমান State পর্যবেক্ষণ করে।

২. সেই অনুযায়ী একটি Action গ্রহণ করে।

৩. Environment সেই অ্যাকশনের ফলে বদলে যায় এবং নতুন একটি State তৈরি হয়।

৪. একই সাথে এনভায়রনমেন্ট এজেন্টকে একটি Reward (পুরস্কার বা শাস্তি) প্রদান করে।

৫. এজেন্ট সেই রিওয়ার্ড থেকে শেখে এবং পরবর্তী সময়ে আরও ভালো সিদ্ধান্ত নেওয়ার প্রস্তুতি নেয়।

মূল লক্ষ্য: এমন এক কৌশল (Policy) খুঁজে বের করা যাতে দিনশেষে সবথেকে বেশি রিওয়ার্ড সংগ্রহ করা যায়।

💡 বাস্তব জীবনের জাদুকরী কিছু উদাহরণ

➜ সেলফ-ড্রাইভিং কার (Self-Driving Cars): টেসলা বা ওয়েইমোর মতো গাড়িগুলো রাস্তায় চলার সময় এই পদ্ধতিতে শেখে। ট্রাফিকে ঠিকমতো চললে রিওয়ার্ড পায়, আর ধাক্কা খেলে নেগেটিভ পয়েন্ট।

➜ গেমপ্লে (AlphaGo): ২০১৬ সালে গুগলের DeepMind-এর এআই 'AlphaGo' যখন বিশ্বের সেরা গো (Go) খেলোয়াড় লি সেডলকে হারিয়ে দিয়েছিল, তার পেছনে ছিল এই রেইনফোর্সমেন্ট লার্নিং! মেশিন নিজের সাথেই লাখ লাখ বার গেম খেলে এই দক্ষতা অর্জন করেছিল।

➜ রোবোটিক্স: কোনো প্রোগ্রামিং ছাড়াই একটি রোবটকে শুধু পড়ে যাওয়ার জন্য শাস্তি আর সোজা হয়ে হাঁটার জন্য পুরস্কার দিয়ে হাঁটা শেখানো যায়।

💻 কোডিং ল্যাব: চলুন হাতে-কলমে দেখি!

RL শেখার জন্য সবথেকে জনপ্রিয় ল্যাব হলো OpenAI Gym। নিচে একটি পোলের ভারসাম্য রক্ষা করার (CartPole) সিম্পল কোড দেওয়া হলো:

```
import gym
# ১. পরিবেশ তৈরি (CartPole গেম)
env = gym.make('CartPole-v1')
state = env.reset()
total_reward = 0
for step in range(1000):
   # ২. এজেন্ট একটি র‍্যান্ডম পদক্ষেপ নিচ্ছে
   action = env.action_space.sample()
   next_state, reward, done, info = env.step(action)
   total_reward += reward
   if done:
       print(f"Game Over! Total Reward: {total_reward} | Steps Survived: {step}")
       break
```

⚖️ ভালো এবং মন্দের লড়াই

✅ সুবিধা: এটি দীর্ঘমেয়াদী লক্ষ্য অর্জনের জন্য এবং অতি জটিল পরিবেশে কাজ করার জন্য সেরা। এর জন্য কোনো লেবেলযুক্ত ডেটার প্রয়োজন হয় না।

❌ চ্যালেঞ্জ: এটি শিখতে অনেক সময় এবং কোটি কোটি বার চেষ্টার প্রয়োজন হয়। এছাড়া পুরস্কারের নিয়মগুলো সেট করা বেশ জটিল।

🎯 আজকের ব্রেইন-টিজার (কুইজ!)

ধরুন, আপনি আপনার একটি 'রোবট ভ্যাকুয়াম ক্লিনার'কে ঘর পরিষ্কার করা শেখাচ্ছেন।

নিয়ম হলো: সে ধুলো পরিষ্কার করলে পাবে +১০ পয়েন্ট, আর কোনো আসবাবপত্রের সাথে ধাক্কা খেলে পাবে -৫ পয়েন্ট।

আপনার জন্য প্রশ্ন: কিছুদিন পর আপনি দেখলেন রোবটটি একটি অদ্ভুত কাজ করছে। সে নিজে থেকেই কিছুটা ধুলো ফেলছে এবং আবার সেটি পরিষ্কার করে +১০ পয়েন্ট নিচ্ছে। সে সারাদিন শুধু এটাই করছে, কিন্তু পুরো ঘর পরিষ্কার করছে না!

এআই-এর এই আচরণকে কী বলে? এবং আপনি একজন ইঞ্জিনিয়ার হিসেবে রিওয়ার্ড সিস্টেমে কী পরিবর্তন আনবেন যাতে রোবটটি এই চালাকি না করে পুরো ঘর পরিষ্কার করে?