AI & ML DEEP DIVE SERIES

পর্ব ০২

আনসুপারভাইজড লার্নিং (Unsupervised Learning)

🚀 AI & ML Deep Dive: পর্ব ০২ - আনসুপারভাইজড লার্নিং (Unsupervised Learning)

গত পর্বে আমরা শিখেছিলাম কীভাবে শিক্ষক বা 'লেবেল' দেখে মেশিন শেখে। কিন্তু বাস্তবে সব সময় কি আমাদের কাছে উত্তর বা লেবেল থাকে?

ডেটার মহাসমুদ্রে যখন কোনো 'শিক্ষক' ছাড়াই মেশিনকে ছেড়ে দেওয়া হয় তখন সে কীভাবে নিজের বুদ্ধি কাজে লাগিয়ে প্যাটার্ন খুঁজে বের করে? চলুন আজ জেনে নিই আনসুপারভাইজড লার্নিং-এর জাদু! ✨

খেলনা গোছানো এবং আমাদের শৈশব: শিক্ষক ছাড়াই শেখা?

মনে পড়ে ছোটবেলায় যখন আপনাকে এক ঝুড়ি নানা রকমের খেলনা (বল, গাড়ি, পুতুল) দেওয়া হতো? কেউ আপনাকে বলে দেয়নি কোনটি কী, কিন্তু আপনি নিজে থেকেই গোলোগুলোকে একপাশে, চাকাওয়ালাগুলোকে অন্যপাশে আর পুতুলগুলোকে আলাদা করে রাখতেন।

এখানে আপনার কোনো শিক্ষক (Supervisor) ছিল না। আপনি খেলনাগুলোর আকার বা বৈশিষ্ট্যের মিল দেখে তাদের আলাদা করেছেন। মেশিন লার্নিংয়ের এই "নিজে নিজে গোপন প্যাটার্ন খুঁজে বের করার" পদ্ধতিকেই বলা হয় আনসুপারভাইজড লার্নিং। 🤖

অচেনা ভাষার গানের প্লেলিস্ট

আরেকটি উদাহরণ দেওয়া যাক। ধরুন আপনি এমন এক দেশের গান শুনছেন যার ভাষা আপনি জানেন না (কোনো লেবেল নেই)। কিন্তু আপনি খেয়াল করলেন কিছু গান High Energy আবার কিছু গান Soft/Melodic।

ভাষা না বুঝলেও আপনি সুর আর তাল শুনে গানগুলোকে মনে মনে আলাদা দুটি ক্যাটাগরিতে ভাগ করে ফেললেন। এটাই হচ্ছে আনসুপারভাইজড লার্নিং যেখানে আপনি তথ্যের গভীরের 'সুর' বা 'প্যাটার্ন' ধরে ডেটাকে গুছিয়ে ফেলছেন। 🎧

🔍 মেকানিজম: পর্দার আড়ালে যা ঘটে (The Core Logic)

সুপারভাইজড লার্নিংয়ে আমাদের কাছে Labeled Data ছিল। কিন্তু এখানে আমাদের কাছে আছে শুধু Unlabeled Data (শুধু ইনপুট)। মেশিন এখানে কোনো গাণিতিক ইকুয়েশনের অপেক্ষায় থাকে না, বরং সে ডেটার ভেতরে লুকিয়ে থাকা স্ট্রাকচার বা মিল খুঁজে বের করে।

একে মূলত ৩টি প্রধান ভাগে ভাগ করা যায়:

1️⃣ ক্লাস্টারিং (Clustering) – "ডেটার ভিড়ে দল গঠন করা"

সহজ কথায়, ক্লাস্টারিং হলো এমন একটি পদ্ধতি যেখানে মেশিন কোনো লেবেল ছাড়াই ডেটার বৈশিষ্ট্য (Features) বিশ্লেষণ করে একই ধরনের ডেটাগুলোকে আলাদা আলাদা গ্রুপে ভাগ করে।

➜ উদাহরণ: ধরুন যে মেশিনের কাছে ১০০০টি ছবির ডেটা আছে। মেশিন দেখলো কিছু ছবিতে চাকা আছে, কিছু ছবিতে ডানা আছে। সে নিজে থেকেই চাকাওয়ালাগুলোকে 'গ্রুপ এ' এবং ডানাওয়ালাগুলোকে 'গ্রুপ বি'-তে ফেলে দিল। সে জানে না এগুলো 'গাড়ি' বা 'প্লেন', সে শুধু মিল দেখে আলাদা করেছে।

➜ K-Means অ্যালগরিদম: এটি ডেটার মাঝে কিছু কেন্দ্রবিন্দু (Centroids) ঠিক করে এবং প্রতিটি ডেটা পয়েন্ট তার সবথেকে কাছের কেন্দ্রের সাথে যুক্ত হয়ে একটি দল বা ক্লাস্টার তৈরি করে।

2️⃣ অ্যাসোসিয়েশন (Association) – "লুকিয়ে থাকা সম্পর্ক আবিষ্কার"

অ্যাসোসিয়েশন রুল লার্নিং মূলত ডেটার ভেতরে "If-Then" সম্পর্ক খুঁজে বের করে। অর্থাৎ, "যদি কেউ A কেনে, তবে তার B কেনার সম্ভাবনা কতটুকু?"। এটি মূলত বড় বড় ট্রানজ্যাকশন ডেটা অ্যানালাইসিস করে। একে 'মার্কেট বাস্কেট অ্যানালাইসিস'ও বলা হয়।

➜ উদাহরণ: সুপার শপে দেখা যায়, যারা পাউরুটি কেনে তাদের মধ্যে ৮০% মানুষই মাখন কেনে। এই রিলেশনটি খুঁজে বের করে অ্যাসোসিয়েশন। এই যে দুটি সম্পূর্ণ ভিন্ন পণ্যের মাঝে একটা গোপন সম্পর্ক এটি খুঁজে বের করাই হলো অ্যাসোসিয়েশন।

➜ অ্যালগরিদম: Apriori Algorithm- এই অ্যালগরিদমটি বারবার ঘটে এমন আইটেম সেটগুলো খুঁজে বের করে এবং তাদের মধ্যকার সম্পর্কের শক্তি (Confidence/Lift) পরিমাপ করে।

3️⃣ ডাইমেনশনালিটি রিডাকশন (Dimensionality Reduction) – "জটিলতাকে সহজ করা"

কখনো কখনো আমাদের ডেটাসেটে এত বেশি তথ্য (Features) থাকে যে মেশিন কনফিউজড হয়ে যায়। ডাইমেনশনালিটি রিডাকশন হলো সেই অতিরিক্ত বা অপ্রয়োজনীয় তথ্য বাদ দিয়ে মূল তথ্যটুকু ধরে রাখা।

➜ উদাহরণ: ধরুন, আপনি একটি বড় ৩ ঘণ্টার মুভি দেখলেন এবং আপনার বন্ধুকে সেটি ৫ মিনিটে বুঝিয়ে বললেন। আপনি মুভির সব দৃশ্য বলেননি কিন্তু মূল কাহিনীটি (Essence) ঠিকই বলেছেন। এটাই হলো ডাইমেনশনালিটি রিডাকশন। একে বলা হয় 'Curse of Dimensionality'। ডেটা যত বেশি জটিল হয় মডেল ট্রেন হতে তত বেশি সময় লাগে এবং ভুল করার সম্ভাবনা বাড়ে।

➜ অ্যালগরিদম: PCA (Principal Component Analysis)- এটি একটি গাণিতিক পদ্ধতি যা ডেটার মূল ভেরিয়েন্স বা বৈচিত্র্য ঠিক রেখে অনেকগুলো ডাইমেনশনকে কমিয়ে মাত্র ২ বা ৩টি ডাইমেনশনে নিয়ে আসে যাতে সেটি সহজেই প্লট করা বা বোঝা যায়।

💻 কোডিং ল্যাব: চলুন হাতে-কলমে দেখি!

আনসুপারভাইজড লার্নিংয়ের সবথেকে জনপ্রিয় অ্যালগরিদম K-Means Clustering দিয়ে চলুন ডেটা গ্রুপিং করি:

```
from sklearn.cluster import KMeans
from sklearn import datasets
# ১. ডেটাসেট লোড (এখানে কোনো 'y' বা আউটপুট নেই)
iris = datasets.load_iris()
X = iris.data
# ২. মডেল তৈরি (আমরা চাই ডেটা ৩টি গ্রুপে ভাগ হোক)
kmeans = KMeans(n_clusters=3)
```

```
kmeans . fit(X)   ## Remove the space between the dot here
# ৩. ক্লাস্টার আইডি বের করা
labels = kmeans.labels_
print("মেশিন ডেটাগুলোকে এই ৩টি ক্লাস্টারে ভাগ করেছে:", labels)
```

কী ঘটছে এখানে? লক্ষ্য করুন, আমরা কিন্তু মেশিনকে বলিনি কোনটি কোন ফুল। মেশিন শুধু পাপড়ির সাইজ দেখে নিজেই ৩টি আলাদা গ্রুপ বানিয়ে ফেলেছে! 🤯

💡 বাস্তব জীবনের কিছু জাদুকরী উদাহরণ

➜ স্পটিফাই/ইউটিউব ডিসকভারি: আপনার রুচি অনুযায়ী নতুন গান বা ভিডিও সাজেস্ট করা।

➜ অ্যানোমালি ডিটেকশন: ব্যাংক একাউন্টে হঠাৎ করে কোনো অস্বাভাবিক লেনদেন শনাক্ত করা।

➜ জেনেটিক রিসার্চ: ডিএনএ সিকোয়েন্স বিশ্লেষণ করে বিভিন্ন প্রজাতি বা রোগের বৈশিষ্ট্য বের করা।

⚖️ ভালো এবং মন্দের লড়াই

✅ সুবিধা: এটি এমন সব প্যাটার্ন খুঁজে পায় যা মানুষের চোখে ধরা পড়ে না। এছাড়া লেবেল করার ঝামেলা নেই বলে যেকোনো বিশাল ডেটা নিয়ে কাজ করা সহজ।

❌ চ্যালেঞ্জ: যেহেতু কোনো 'সঠিক উত্তর' দেওয়া নেই, তাই আউটপুট সবসময় ১০০% আপনার মনমতো নাও হতে পারে। এছাড়া এর গাণিতিক জটিলতা একটু বেশি।

🎯 আজকের ব্রেইন-টিজার (কুইজ!)

ধরুন আপনার ঝুড়িতে থাকা আপেল আর কমলাগুলোর মধ্যে কিছু ফল পচা (Rotten)। আপনি মেশিন লার্নিং ব্যবহার করে এই সমস্যার সমাধান করতে চান:

পরিস্থিতি ১: আপনি মেশিনকে কোনো নাম বা লেবেল বললেন না। শুধু বললেন "এই ঝুড়ির ফলগুলোকে এমন দুটি দলে ভাগ করো যেন পচা ফলগুলো একপাশে আর ভালো

ফলগুলো অন্যপাশে থাকে।" মেশিন তাদের গায়ের রঙ আর গন্ধের প্যাটার্ন দেখে আলাদা করে ফেলল।

পরিস্থিতি ২: আপনি মেশিনকে আগে থেকে ১০০টি পচা ফলের ছবি এবং ১০০টি ভালো ফলের ছবি দেখিয়ে দিলেন। এরপর তাকে নতুন ঝুড়ি থেকে পচা ফল খুঁজে বের করতে বললেন।

আপনার জন্য প্রশ্ন: এই দুটি আলাদা পরিস্থিতিতে লার্নিংয়ের ধরণ কীভাবে পরিবর্তিত হয়েছে? কোনটি Supervised আর কোনটি Unsupervised? এবং সবথেকে গুরুত্বপূর্ণ বাস্তব জীবনে কোন পদ্ধতিটি বেশি নির্ভুল (Accurate) ফলাফল দেবে বলে আপনি মনে করেন?